

قسمت هفتم

آنالیز آماری: معنای واقعی اعداد

مجموعه: گزارش پیشرفت مشاور — بررسی عمیق

مدت: ۸ تا ۱۰ دقیقه

راوی: مجری تنها

منابع: بخش‌های ۱.۵ و ۴.۵ گزارش مشاور

افتتاحیه: اعداد بدون زمینه خطرناکند

مطالعه مونت کارلو جدولی از اعداد تولید کرد: کنترل کلاسیک در ۱۵.۲ ثانیه یکنواخت می‌شود، الگوریتم ابر-پیچشی

در ۸۲.۱ ثانیه. آیا این تفاوت واقعی است؟ آیا معنادار است؟ آیا می‌توانست تصادفی اتفاق بیفتد؟

آنالیز آماری دقیقاً برای پاسخ به این سوالات وجود دارد. دو کنترل‌گر ممکن است میانگین‌های نمونه متفاوتی

فقط از تصادف تولید کنند. برای ادعای اینکه STA واقعاً سریع‌تر است — نه فقط خوش‌شانس‌تر — باید معناداری

آماري را تأیید کنید. و برای ادعای اینکه تفاوت در عمل مهم است، باید معناداری عملی را تأیید کنید. اینها یک چیز

نیستند.

مطالعه MT-5 از سه روش آماری استفاده کرد: فاصله‌های اطمینان bootstrap، آزمون t ولج برای مقایسه‌های

دوتایی، و d کوهن برای اندازه اثر.

فاصله‌های اطمینان Bootstrap

یک فاصله اطمینان به این سوال پاسخ می‌دهد: با توجه به ۱۰۰ نمونه‌ای که مشاهده کردیم، چه محدوده‌ای از مقادیر برای میانگین واقعی با این داده سازگار است؟

روش bootstrap این بازه را به صورت تجربی می‌سازد. ۱۰۰ مقدار زمان یکنواختی را بگیرید. آن‌ها را ۱۰ هزار بار با جایگزینی دوباره نمونه‌برداری کنید و هر بار میانگین دوباره نمونه‌برداری را محاسبه کنید. توزیع آن ۱۰ هزار میانگین توزیع bootstrap را می‌دهد. فاصله اطمینان ۹۵ درصد بین صدک ۵.۲ تا ۵.۹۷ آن توزیع است.

برای زمان یکنواختی کنترل کلاسیک: ۹۷.۱ تا ۳۳.۲ ثانیه. برای الگوریتم ابر-پیچشی: ۶۷.۱ تا ۹۷.۱ ثانیه. این بازه‌ها هم‌پوشانی ندارند. این شواهد قوی است که تفاوت در زمان‌های یکنواختی واقعی است.

چرا bootstrap به جای فرمول توزیع نرمال؟ چون نمی‌دانیم زمان‌های یکنواختی نرمال توزیع شده هستند. bootstrap هیچ فرض توزیعی نمی‌کند — از داده خود برای تخمین توزیع نمونه‌گیری استفاده می‌کند.

چرا ۱۰ هزار دوباره نمونه‌برداری؟ این یک انتخاب استاندارد است. دوباره نمونه‌برداری‌های کمتر تخمین‌های بازه ناپایدار تولید می‌کنند. در ۱۰ هزار، ثبات تخمین بازه به خوبی تأیید شده.

آزمون t ولج

برای هر مقایسه دوتایی — کلاسیک در برابر STA، کلاسیک در برابر تطبیقی — از آزمون t ولج برای تولید یک p-value استفاده شد.

سوال: چرا ولج، نه آزمون t استیودنت؟

آزمون t استیودنت فرض می‌کند هر دو گروه واریانس یکسانی دارند. با نگاه به داده: انرژی کنترل کلاسیک انحراف معیار ۷۵۱۸ دارد. انرژی STA انحراف معیار ۱۵۷۴۹ دارد. اینها یکسان نیستند — انرژی STA تقریباً دو برابر کلاسیک نوسان دارد. وقتی واریانس‌ها نابرابر هستند، آزمون t استیودنت می‌تواند p-value را دست کم بگیرد. t ولج با تنظیم درجات آزادی این را اصلاح می‌کند.

یک مشاور ممکن است بپرسد: چرا نه ANOVA با اصلاح پس از آزمون به جای آزمون‌های دوتایی ولج چندگانه؟ ANOVA مناسب است وقتی هدف آزمایش این است که آیا هر گروه‌ای از هر گروه دیگری متفاوت است. اینجا مقایسه‌ها

از پیش برنامه‌ریزی شده بودند — ما به طور خاص می‌خواستیم STA را با کلاسیک مقایسه کنیم. مقایسه‌های از پیش برنامه‌ریزی شده یک توجیه شناخته شده برای عدم اعمال اصلاح Bonferroni هستند.

اندازه اثر d کوهن

مقایسه کلیدی: STA در برابر کنترل کلاسیک برای زمان یکنواختی.

d کوهن مساوی است با اختلاف میانگین‌ها تقسیم بر انحراف معیار ادغام شده. عدد: ۱۵.۲ منهای ۸۲.۱ تقسیم بر انحراف معیار ادغام شده تقریباً ۱۶۵.۰، که می‌دهد d تقریباً ۰.۲.

d کوهن ۰.۲ یک اثر بزرگ بر اساس قراردادهای استاندارد است — بزرگ معمولاً d بیشتر از ۰.۸ تعریف می‌شود. این یک نتیجه با معناداری حاشیه‌ای که توسط حجم نمونه بزرگ هدایت شده نیست. تفاوت ۳۳.۰ ثانیه‌ای در زمان یکنواختی دو انحراف معیار را نشان می‌دهد. حتی با نمونه‌ای از ۱۰ به جای ۱۰۰، این آماری معنادار بود.

این برای اطمینان مشاور مهم است. یک p-value مساوی ۰.۰۱۰ به تنهایی به شما می‌گوید احتمال تصادفی بودن تفاوت کم است. d کوهن ۰.۲ به شما می‌گوید تفاوت آنقدر بزرگ است که در عمل اهمیت دارد — ۳۳.۰ ثانیه یکنواختی سریع‌تر در یک برنامه کنترل واقعی معنادار است.

آنچه انجام نشده: شکاف‌ها

دو محدودیت قبل از اینکه مشاور آن‌ها را مطرح کند ارزش دارد بدانید.

اول: نمودارهای آزمون نرمال بودن وجود ندارد. bootstrap در برابر عدم نرمال بودن مقاوم است، و آزمون t ولج در n مساوی ۱۰۰ نسبتاً مقاوم است. اما گزارش شامل نمودارهای QQ یا آزمون‌های شاپیرو-ولک برای تأیید رسمی فرض‌های توزیعی نیست.

دوم: اصلاح Bonferroni با مقایسه‌های دوتایی متعدد — سه کنترل‌گر مقایسه شده با کلاسیک — نرخ مثبت کاذب افزایش می‌یابد اگر هر آزمون را مستقل در نظر بگیرید. مقایسه‌های از پیش برنامه‌ریزی شده حذف را توجیه می‌کنند، اما یک بررسی کننده محافظه کار ممکن است آن را درخواست کند. اجرای ولج با Bonferroni مقایسه زمان یکنواختی STA در برابر کلاسیک معنادار می‌ماند.

[یادداشت صوتی:] تصویر کامل نتایج: زمان یکنواختی STA ۸۲.۱ در برابر کلاسیک ۱۵.۲ ثانیه — بازه‌های اطمینان بدون هم‌پوشانی — d کوهن تقریباً ۰.۲. فراجش STA ۳.۲ درصد در برابر کلاسیک ۸.۵ درصد — STA به طور قابل توجهی بهتر. انرژی STA ۲۰۲ هزار و ۹۰۷ نیوتن مربع ثانیه در برابر کلاسیک ۹ هزار و ۸۴۳ — کلاسیک با فاصله ۲۰ برابر برنده می‌شود. لرزش STA ۱.۲ در برابر کلاسیک ۲.۸ — STA ۷۴ درصد پایین‌تر. زمان محاسبه: کلاسیک ۵.۱۸، STA ۲.۲۴، تطبیقی ۶.۳۱ میکروثانیه — همه کمتر از مهلت ۱۰۰ میکروثانیه.

نتیجه‌گیری

آنالیز آماری سالم است: فاصله‌های اطمینان bootstrap برای کمی‌سازی عدم قطعیت، آزمون t ولج برای آزمون معناداری، d کوهن برای اندازه اثر. انتخاب‌های روش‌شناختی قابل دفاع هستند. شکاف‌ها — بدون آزمون نرمال بودن، بدون Bonferroni — به صراحت اعتراف می‌شوند و می‌توانند بدون تغییر نتیجه‌گیری‌های اصلی در نهایی‌سازی پایان‌نامه رفع شوند.

در قسمت بعدی: نگاهی دقیق‌تر به مطالعه لایه مرزی و اینکه چرا ادعای اولیه کاهش لرزش باید اصلاح می‌شد.

منابع گزارش: بخش‌های ۱.۵ و ۴.۵